

为什么学术界的大模型数学 RL 没有像 AlphaZero 那样轻易解决?

汇报人：杨凯森，黄禹

猜测一：是不是因为状态 / 动作空间太大？

这个猜测很自然

围棋只有 361 个格子，而大模型词表可以有 16 万 token。

是不是因为搜索空间太大，所以 RL 很难像 AlphaZero 那样迭代？

但动作集合可以工程化收缩

模型词表可以很大，但数学推理真正需要活跃保留的符号集合小得多。

如果只考虑数学符号和推理格式，几百个 token 量级就能覆盖相当多场景。

160k tokens → ~300 math tokens

猜测二：是不是因为合法性约束太弱？

这个猜测也很自然

围棋每一步几乎都是合法落子。

而语言模型会写出很多非法表达、无意义推导、格式错误答案。

但合法性可以交给编译器

可以接入 Lean / parser / 类型检查器，在生成过程中做静态检查。
这样模型不一定能写出正确证明，但至少可以被限制在合法表达附近。

LM + compiler feedback


固定题集意味着固定信息源

给定训练集 $D = \{q_1, \dots, q_n\}$, RL 反复在这些题目上 rollout, 并用 verifier reward 更新模型。

如果每道题 q_i 的信息积分有上限 C_i , 那么整个固定数据集的信息量也有上限。

$$A_D(T) = \sum_i A_i(T) \leq \sum_i C_i$$

左图展示的是每个 source prompt 已实现的信息积分与理论上限。



我们怎么定义 RL 的平均信息量?

给定题目和 rollout

题目 q_i , 训练 step t 的模型是 π_t 。

一次 rollout 是从当前模型采样一条解答轨迹。

$$\tau_i(t) \sim \pi_t(\cdot \mid q_i)$$

verifier 给出 reward。

$$R_i(t)=r(q_i,\tau_i(t))$$

一次 rollout 的平均信息量

先把 reward 仿射变换到 0-1，避免不同 reward 尺度不可比。

$$R_{01_i}(t)=(R_i(t)-R_{\min})/(R_{\max}-R_{\min})$$

一次 rollout 属于当前 reward 分布；该分布的方差就是它对应的平均信息量。

$$I_i(t)=V[R_{01_i}(t)]$$

二值 reward 时：

$$I_i(t)=p_i(t)(1-p_i(t))\leq 1/4$$

信息积分

沿训练步数累加，就得到题目 q_i 的信息积分。

$$A_i(T)=\sum_{t=0}^{T-1} I_i(t)$$

固定数据集 D 的总信息积分：

$$A_D(T)=\sum_{q_i\in D} A_i(T)$$

如果 $p_i(t)$ 接近 0 或 1，rollout reward 几乎不再有差异， $I_i(t)$ 接近 0；只有 $p_i(t)$ 接近 1/2 时，每次 rollout 的平均信息量最大。


我们先看 AlphaZero: 它为什么不会很快耗尽信息?

背景: 自博弈 + MCTS

当前 policy/value network 通过 MCTS 搜索来落子。

模型和自己对弈, 胜负结果再训练新的 policy/value network。

新模型继续成为下一轮自己的对手, 数据分布会被不断刷新。




Connect Four 作为例子


自博弈里双方实力接近时, 结果基本是一半正样本、一半负样本。

$$p(\text{win}) \approx 1/2, I_t = V[R_t] \approx 1/4$$

实验里 self-play 相比固定对手更稳, 弱对手胜率也更高。





那么在数学题上呢？先看数据集只有 1 道题



DAPO-17k completed single-question sweeps top-50：每个小图都是“只训练这一道题”的独立实验；蓝线是 $H(p)$ ，橙虚线是 p 。 p 接近 1 后，信息量迅速回到 0。

再看数据集有多道题的情况




DAPO-17k sweep 前 30 个题目：上半部分是每题 pass-rate p 的轨迹，下半部分是同一批题的信息量 H / variance 轨迹。多题数据集更像若干有限预算的叠加。

多道题：多数信号近似可加，但相互作用较弱

如果题目之间相互作用弱，那么增加题数可以增加总信息量；但总上限仍然随固定题集规模受限。

距离一：用性能向量



每一行就是一道题的 fingerprint

训练题目 i, 然后在同一组 target / anchor 上测试性能。


$$x_i = (p_{i1}, p_{i2}, \dots, p_{in})$$

如果两道题改善的是同一批 target, 它们的方向相近。


$$d_{\cos}(i, j) = 1 - \cos(x_i, x_j)$$

这给出一个近似无向的题目距离空间。


距离二：用自归一化迁移



p_{ij} ：训练 i 后， j 的性能提升。




p_{ii} ：训练 i 后， i 自己的提升；用它归一化不 R_{ij} 越大， i 对 j 的外溢越强；保留大边即可画图。



核心量很简单： $R_{ij} = p_{ij} / p_{ii}$ 。它天然是有方向的；如果一定要对称距离，可以再把 R_{ij} 和 R_{ji} 合并。

左边看收缩，右边看题目在 transfer space 中的位置。几何关系告诉我们哪些题
可以互相带动。

固定数据集上的 RL：把西瓜缩成籽



每个籽是一道题

原始模型是一个宽的输出分布。

固定题集上的 RL 会降低 action entropy，把概率质量收缩到若干个题目解法附近。

这些籽之间的距离，就是刚才由 transfer 定义出的数据集几何。

前面的数学 RLVR

一道题 q_i , 采样一条 rollout τ , 再由 verifier 给出二值 reward。

$$q_i \rightarrow \tau \rightarrow R_i \in \{0, 1\}$$

所以平均信息量可以写成 binary reward variance。

$$I_i(t) = \text{Var}[R_i(t)] = p_i(t)(1 - p_i(t))$$

Diffusion RL 的对应物

一个 prompt c_i , 采样图像 x , 再由 reward model 给出连续 scalar score。

$$c_i \rightarrow x \sim \pi_t(\cdot | c_i) \rightarrow R(c_i, x) \in \mathbb{R}$$

因此要看同一 prompt 下 reward distribution 还有没有可区分的宽度。

$$I_i(t) = \text{Var}_x[R(c_i, x)]$$

Binary verifier 只是 $\text{Var}[R]$ 的特例；在 diffusion 里，更自然的问题是 mean reward 是否上升、reward spread 是否变窄、high-reward tail 是否还存在。

Reward 不是 ground truth

图像 reward model 更像 learned proxy，而不是数学 verifier。

$$R_{\text{proxy}}(c, x) \neq R_{\text{human}}(c, x)$$

高 variance 可能是有用信号，也可能只是 reward hacking 空间。

多 reward 的冲突本身是信息

图像质量通常不是单目标：美学、prompt alignment、人类偏好、多样性会互相拉扯。

$$r(c, x) = [R_{\text{aes}}, R_{\text{align}}, R_{\text{pref}}, \dots]$$

reward ranking 的 disagreement 可以揭示 tradeoff、bias 和可优化方向。

Reward 之间可能低维耦合

多个 reward 看似独立，但实际可能共享同一组视觉偏好或模型偏差。

$$\Sigma_R(c) = \text{Cov}_x[r(c, x)]$$

分析 covariance / effective rank 可以判断多 reward 是否真的提供了更多独立信息。

Future todo：把 diffusion RL 也看成信息几何问题，分析 reward variance 从哪里来、proxy bias 有多大、多个 reward 是否冲突，以及多 reward 是否真的增加独立信号维度。

如果固定题集信息有限，怎么增加信息？

更多相对独立的题

如果题目基本独立，增加题数会近似增加总信息预算。

更丰富的 reward 信号

不仅看最终答案，还看 proof state、Lean 检查、步骤级 reward、partial credit。

生成式环境

Diffusion / theorem generation / AI task generation 可以不断制造新边界。

也就是说，未来真正需要的是会自我生成任务、验证任务、更新任务分布的系统。

一句话总结

AlphaZero 的强大来自开放式自博弈带来的持续信息流；固定数学数据集上的 RL 更像有限信息的锐化过程。

Bounded

每道题的信息积分有限。

Additive

题目之间相互作用弱时，总信息近似随题数增长。

Geometric

题目之间的 transfer 可以定义 prompt space geometry。

17/17

谢谢大家。